Aprendizaje Supervisado

Planeación didáctica

14 sesiones · 2 horas por sesión · 28 horas presenciales

DESCRIPCIÓN DEL CURSO

Este curso ofrece a los estudiantes una introducción rigurosa y práctica al aprendizaje automático supervisado. Los estudiantes construirán un flujo de trabajo sólido que va de los datos crudos a modelos listos para producción, abarcando los cuatro pilares de la disciplina: preparación de datos, regresión, clasificación y métodos de ensamble. Cada sesión combina fundamentos conceptuales con implementación práctica en Python (scikit-learn, pandas, NumPy, Matplotlib).

REQUISITOS PREVIOS Y RESULTADOS DE APRENDIZAJE

Requisitos previos	Resultados de aprendizaje
• Programación introductoria en Python • Estadística y probabilidad básicas • Fundamentos de álgebra lineal • Familiaridad con NumPy / pandas (recomendable)	• Preparar, limpiar y generar variables a partir de conjuntos de datos reales • Construir y ajustar modelos de regresión y clasificación • Aplicar técnicas de ensamble para mejorar el desempeño de los modelos • Evaluar los modelos con rigor mediante las métricas adecuadas • Entregar un flujo de aprendizaje automático completo (de extremo a extremo) sobre un conjunto de datos nuevo

EVALUACIÓN

Elemento de evaluación	Peso
Ejercicios de laboratorio	**30 %**
Miniproyecto – Regresión	**35 %**
Miniproyecto – Clasificación	**35 %**

CALENDARIO DE SESIONES

#	Módulo	Título de la sesión	Temas principales	Laboratorio / Actividad
1	**Módulo 1** *Preparación de datos*	**Análisis exploratorio de datos (EDA)**	• Estadística descriptiva: media, varianza, asimetría y curtosis • Análisis univariado y bivariado • Matrices de correlación y mapas de calor • Identificación de valores atípicos con diagramas de caja y rango intercuartílico (IQR)	*EDA del conjunto de datos California Housing*
2	**Módulo 1** *Preparación de datos*	**Preprocesamiento de datos**	• Manejo de valores faltantes: estrategias de imputación • Codificación de variables categóricas: etiqueta (label), one-hot, ordinal • Escalado de variables: StandardScaler, MinMaxScaler, RobustScaler • División en entrenamiento / validación / prueba y fuga de datos	*Pipeline de preprocesamiento con Pipeline y ColumnTransformer de scikit-learn*
3	**Módulo 1** *Preparación de datos*	**Ingeniería y selección de variables**	• Creación de variables a partir del dominio; variables polinomiales • Métodos de filtro: umbral de varianza, correlación, información mutua • Métodos de envoltura (wrapper): eliminación recursiva de variables (RFE) • Métodos integrados: selección basada en Lasso	*Comparación de métodos de selección de variables en un conjunto de datos médico*
4	**Módulo 2** *Modelos de regresión*	**Regresión lineal y polinomial**	• Mínimos cuadrados ordinarios (OLS): intuición y solución cerrada • Descenso de gradiente: por lotes, estocástico y por minilotes • Regresión polinomial y el equilibrio sesgo-varianza • Métricas: MAE, MSE, RMSE, R^2	*Predicción de precios de viviendas con modelos lineales y polinomiales*
5	**Módulo 2** *Modelos de regresión*	**Regresión regularizada**	• Sobreajuste: revisión con curvas de aprendizaje • Regresión Ridge (L2): intuición y efecto sobre los coeficientes • Regresión Lasso (L1): dispersión y selección de variables • Elastic Net: equilibrio entre las penalizaciones L1 y L2; ajuste de hiperparámetros	*Comparación de OLS, Ridge y Lasso en un conjunto de datos de alta dimensión*
6	**Módulo 2** *Modelos de regresión*	**Regresión con máquinas de vectores de soporte (SVR)**	• Intuición de SVM de margen duro y de margen blando • La pérdida ε-insensible y los vectores de soporte • Truco del kernel: núcleos lineal, RBF y polinomial • Ajuste de C, ε y parámetros del kernel con GridSearchCV	*SVR sobre un conjunto de datos de consumo de energía*

7	**Módulo 2** *Modelos de regresión*	**Árboles de decisión para regresión y evaluación de modelos**	• Inducción de árboles de decisión: algoritmo CART, impureza (MSE) • Poda: max_depth, min_samples_leaf • Validación cruzada: k pliegues, estratificada y anidada • Análisis sesgo-varianza de todos los modelos de regresión	*Repaso de medio curso + informe comparativo de modelos de regresión*
8	**Módulo 3** *Modelos de clasificación*	**Regresión logística y k vecinos más cercanos (kNN)**	• Clasificación binaria: sigmoide, pérdida logarítmica (log-loss) • Estrategias multiclase: OvR, OvO, softmax • kNN: métricas de distancia, elección de k, maldición de la dimensionalidad • Métricas de clasificación: exactitud (accuracy), precisión, sensibilidad (recall), F1	*Clasificación de correos spam con regresión logística y kNN*
9	**Módulo 3** *Modelos de clasificación*	**Naive Bayes y árboles de decisión para clasificación**	• Repaso del teorema de Bayes; supuesto de independencia condicional • Naive Bayes gaussiano, multinomial y de Bernoulli • Clasificación con árboles de decisión: impureza de Gini vs. ganancia de información • Matriz de confusión, curva ROC, interpretación del AUC	*Clasificación de texto con Naive Bayes; clasificación de diabetes con árboles de decisión*
10	**Módulo 3** *Modelos de clasificación*	**Máquinas de vectores de soporte (SVM)**	• Clasificador de margen máximo y el problema dual • SVM de margen blando: variables de holgura y el parámetro C • Métodos de kernel para clasificación no lineal • SVM multiclase; consejos prácticos para conjuntos de datos grandes	*SVM con kernel RBF para reconocimiento de dígitos en imágenes (subconjunto de MNIST)*
11	**Módulo 3** *Modelos de clasificación*	**Redes neuronales para clasificación**	• Del perceptrón al perceptrón multicapa (MLP): arquitectura • Funciones de activación: ReLU, sigmoide, softmax • Retropropagación y regla de la cadena • Entrenamiento con MLPClassifier de scikit-learn; parada temprana (early stopping)	*Clasificador MLP sobre un subconjunto de Fashion-MNIST*
12	**Módulo 3** *Modelos de clasificación*	**Evaluación de modelos y ajuste de hiperparámetros**	• Métricas avanzadas: MCC, kappa de Cohen, log-loss • Manejo del desbalance de clases: sobremuestreo, SMOTE, pesos de clase • Búsqueda de hiperparámetros: GridSearchCV vs. RandomizedSearchCV • Calibración de modelos y estimación de probabilidades	*Flujo de evaluación completo sobre un conjunto de datos desbalanceado de detección de fraude*

13	**Módulo 4** *Métodos de ensamble*	**Bagging y bosques aleatorios**	• Estrategias de ensamble: bagging, boosting y stacking • Agregación bootstrap (bagging) y reducción de varianza • Bosques aleatorios: aleatoriedad de variables, error fuera de bolsa (out-of-bag) • Importancia de variables y gráficas de dependencia parcial	*Bosque aleatorio sobre un conjunto de datos de riesgo crediticio; análisis de importancia de variables*
14	**Módulo 4** *Métodos de ensamble*	**Boosting: AdaBoost, Gradient Boosting y XGBoost**	• AdaBoost: ponderación adaptativa de aprendices débiles • Máquinas de gradiente boosting (GBM): descenso de gradiente funcional • XGBoost: regularización, submuestreo de columnas, optimizaciones de velocidad • Comparación: cuándo usar cada variante de boosting	*Comparativa de AdaBoost, GBM y XGBoost en un conjunto de datos estilo Kaggle*

SOFTWARE Y RECURSOS

Lenguaje de programación	Python 3.10+
Bibliotecas principales	scikit-learn, pandas, NumPy, Matplotlib, seaborn
Bibliotecas avanzadas	XGBoost, imbalanced-learn
Entorno de desarrollo	Jupyter Notebook / JupyterLab o VS Code con la extensión de Python
Libro de texto recomendado	Aurélien Géron, Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow (3.ª ed.)
Lecturas complementarias	The Elements of Statistical Learning — Hastie, Tibshirani y Friedman (PDF gratuito)
Conjuntos de datos	Repositorio UCI ML, Kaggle, OpenML

Nota: Los temas de las sesiones pueden ajustarse al ritmo del grupo. Todos los archivos de laboratorio y los conjuntos de datos se distribuirán a través de la plataforma del curso.